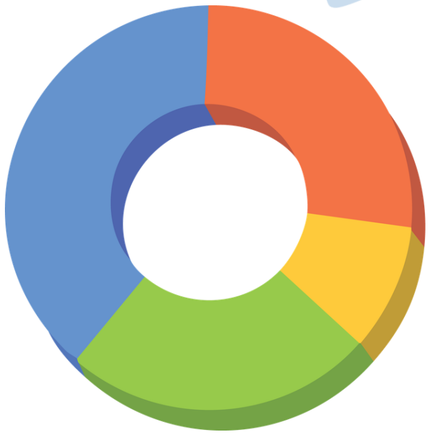
คณิตศาสตร์และสถิติเพื่องานอาชีพ

Mathematics and Statistics for Careers









2 พ.ย. 69

บทที่ 2 : การวิเคราะห์ข้อมูลทางสถิติ

- การวัดแนวโน้มเข้าสู่ส่วนกลาง (Measures of Central Tendency)

  >> ค่ากลางของข้อมูล เช่น ค่าเฉลี่ย ค่ามัธยฐาน และค่าฐานนิยม

  (Mean) (Median) (Mode)

- การระบุตำแหน่งของข้อมูล (Measures of Relative Standing)

  >> ควอร์ไทล์ (Quartiles), เดไซล์ (Deciles), เปอร์เซ็นต์ไทล์ (Percentiles)

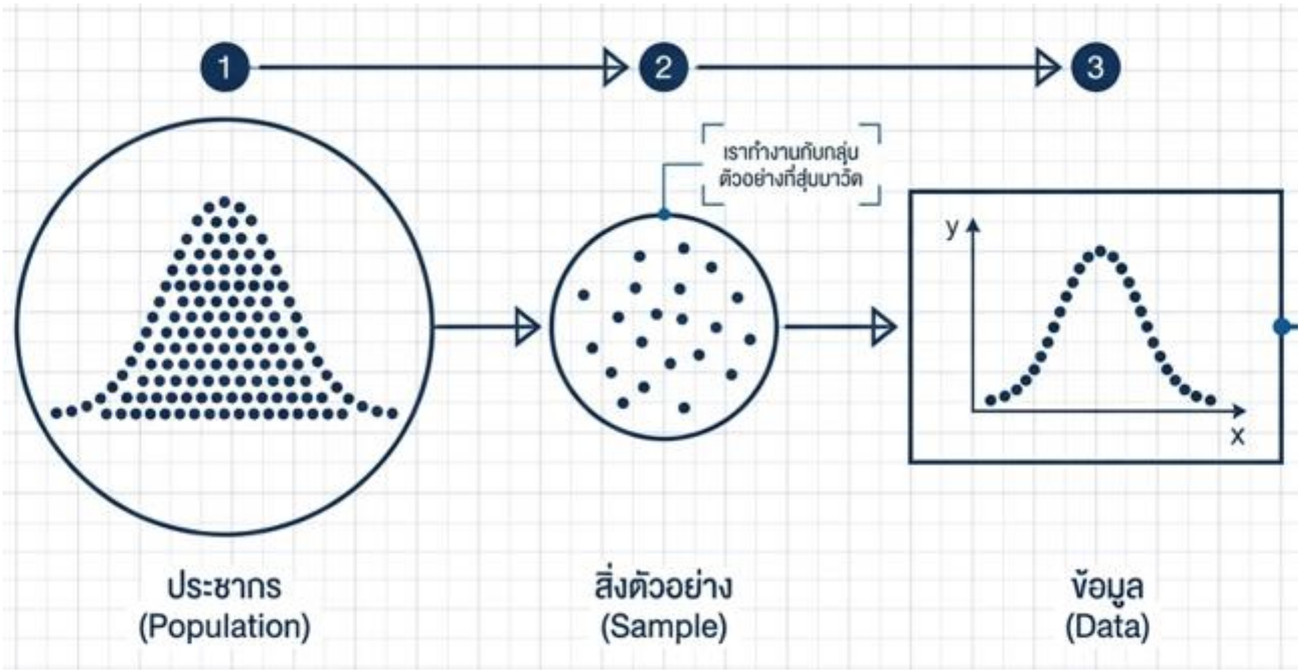
- การวัดการกระจายของข้อมูล (Measures of Dispersion)

  >> พิสัย ส่วนเบี่ยงเบนมาตรฐาน และความแปรปรวน เป็นต้น

การวิเคราะห์ข้อมูล (Analysis of Data)

เมื่อนำข้อมูลมาเสนอด้วยวิธีการในบทที่ 1 และเพื่อให้ข้อมูลเกิดประโยชน์ สามารถนำมาใช้ในการวิเคราะห์ต่อ อาจมีการเพิ่มการคำนวณค่าของข้อมูล เช่น ค่าเฉลี่ย ความแปรปรวน หรือส่วนเบี่ยงเบนมาตรฐาน

โดยในการคำนวณค่าข้อมูลทางสถิติแบ่งออกเป็น **การวัดค่าแนวโน้มสู่ศูนย์กลางของ (Central Tendency)** **การระบุตำแหน่งที่ของข้อมูล (Measures of Relative Standing)** และ **การวัดการกระจาย (Dispersion)**

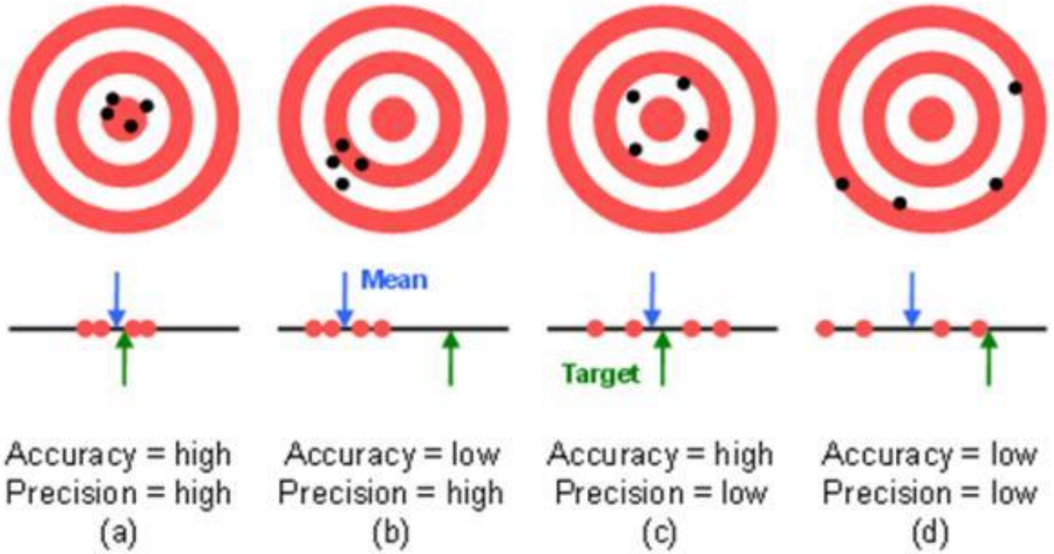


ลักษณะข้อมูลที่เหมาะสมที่จะใช้เป็นตัวแทนของการวิเคราะห์ผลทางสถิติ

ในทางสถิติ ข้อมูลแต่ละชุดจะมีทั้ง**ความเที่ยงตรง (Accuracy)** และ **ความแม่นยำ (Precision)** ที่แตกต่างกัน

หากข้อมูลมีการเบี่ยงเบน (Bias) ไปจากค่าแนวโน้มสู่ศูนย์กลางน้อย -> **ข้อมูลชุดนั้นมีความเที่ยงตรงสูง (High Accuracy)** ขณะเดียวกัน**ข้อมูลจะมีความแม่นยำสูง (High Precision)** -> ถ้าการกระจายของข้อมูลชุดนั้นน้อย

ดังนั้น **ข้อมูลที่ดีควรจะมีความเที่ยงตรงและความแม่นยำสูง** ซึ่งเหมาะสมที่จะใช้เป็นตัวแทนของการวิเคราะห์ผลทางสถิติ



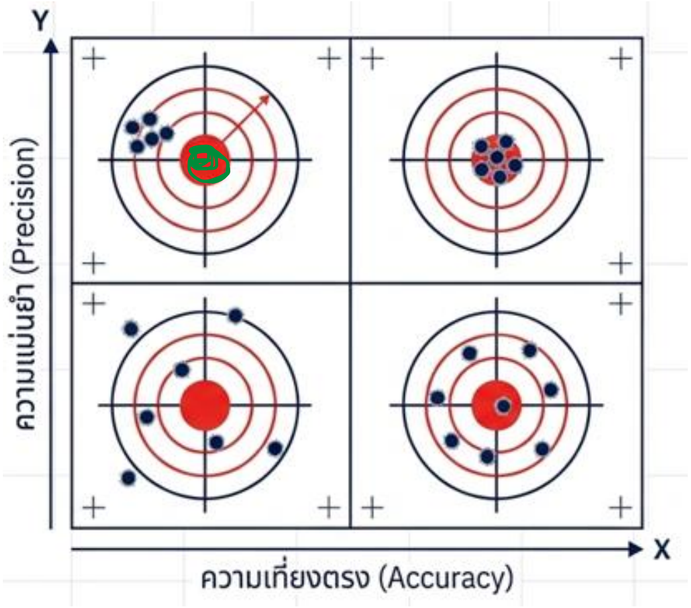
ข้อมูลที่ดีและเหมาะสมที่จะใช้เป็นตัวแทนการวิเคราะห์ ต้องมีความเที่ยงตรงและความแม่นยำสูง

ความเที่ยงตรง (Accuracy) และ ความแม่นยำ (Precision)

หากแบ่งกลุ่มสำรวจเป็น 2 กลุ่ม วัดระยะจำนวน 5 ครั้ง ได้ค่าดังนี้

กลุ่ม A :	กลุ่ม B :
99.98	99.49
100.01	99.51
100.02	99.50
99.99	99.49
100.00	99.50
Mean=100.000	Mean=99.498

กลุ่มไหนวัดได้ดีกว่ากัน?



ถ้าเราทราบว่า Reference/True value = 100.00 m

ข้อมูล กลุ่ม A:

- ใกล้ค่าจริง
- กระจายตัวน้อย

→ Accurate + Precise

ข้อมูล กลุ่ม B:

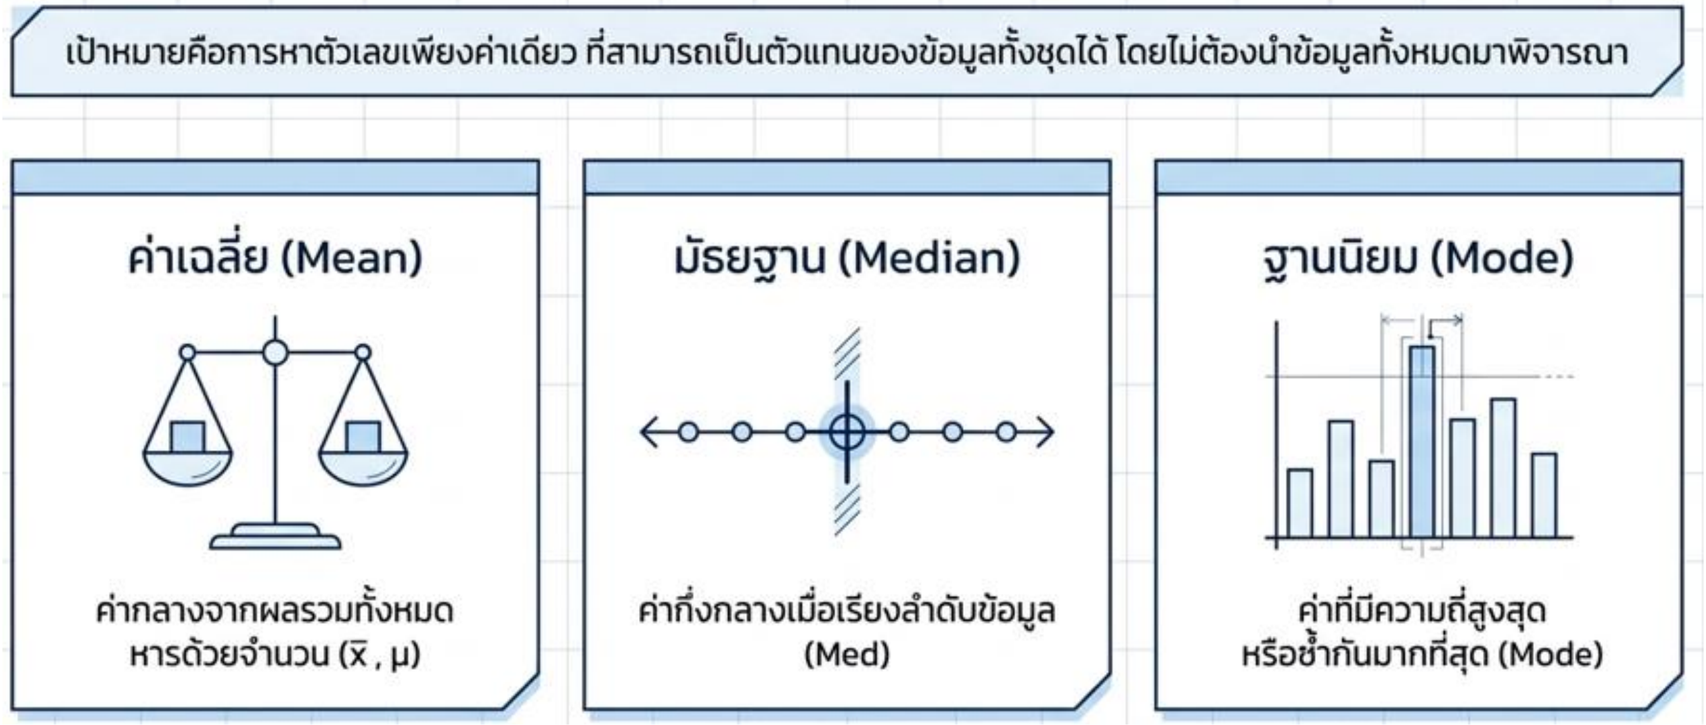
- กระจายตัวน้อย
- แต่ห่างจากค่าจริง

→ Precise แต่ไม่ Accurate

กลุ่ม	Accuracy	Precision
A	สูง	สูง
B	ต่ำ	สูง

การวัดแนวโน้มเข้าสู่ส่วนกลาง (Measures of Central Tendency)

คือ วิธีทางสถิติที่ใช้ในการหาค่ากลางของข้อมูลแต่ละชุด ประโยชน์จากการวัดแนวโน้มเข้าสู่ส่วนกลางก็คือ ได้ตัวแทนข้อมูลซึ่งเป็นตัวเลขจำนวนเดียวแทนคะแนนทั้งหมด โดยไม่จำเป็นต้องนำข้อมูลทั้งชุดมาพิจารณา



ค่าเฉลี่ย (Mean or Average)

ค่ามัธยฐาน (Median)

ฐานนิยม (Mode)

ค่าเฉลี่ย (Mean) → Average

ค่าเฉลี่ย (Mean) คือ ค่ากลางที่คำนวณได้จากการเอาคะแนนทุกตัวมารวมกัน แล้วหารด้วยจำนวนทั้งหมด
แทนด้วยสัญลักษณ์ μ , $\bar{x}$

การหาค่าเฉลี่ยจากประชากร

ถ้ากำหนดให้ $X_1, X_2, X_3, \ldots, X_N$ เป็นข้อมูลชุดหนึ่งมี N จำนวน

$$\mu = \frac{X_1 + X_2 + X_3 + \ldots + X_N}{N} = \frac{\sum_{i=1}^{n} x_i}{N} = \frac{\sum X}{N}$$

การหาค่าเฉลี่ยจากกลุ่มตัวอย่าง

ถ้ากำหนดให้ $x_1, x_2, x_3, \ldots, x_n$ เป็นข้อมูลชุดหนึ่งมี n จำนวน

$$\bar{X} = \frac{x_1 + x_2 + x_3 + \ldots + x_n}{n} = \frac{\sum_{i=1}^{n} x_i}{n} = \frac{\sum x}{n}$$

เมื่อ μ แทน ค่าเฉลี่ยของข้อมูลที่ได้จากประชากร

$\bar{X}$ แทน ค่าเฉลี่ยของข้อมูลที่ได้จากกลุ่มตัวอย่าง

$\sum X$ แทน ผลรวมทั้งหมดของคะแนน

N แทน จำนวนข้อมูลทั้งหมดในประชากร

n แทน จำนวนข้อมูลทั้งหมดในกลุ่มตัวอย่าง

ค่ามัธยฐาน (Median)

มัฐยฐาน (Median) คือ ค่าที่อยู่ในตำแหน่ง**กึ่งกลางของข้อมูล**ทั้งชุด เมื่อได้เรียงค่าของข้อมูลจากน้อยที่สุดไปหาค่ามากที่สุด หรือจากมากที่สุดไปหาน้อยที่สุด สัญลักษณ์ของมัธยฐาน คือ Med

วิธีการหามัธยฐาน ในกรณีที่ข้อมูลมีจำนวนมากสามารถใช้สูตร

$$\textbf{ตำแหน่งมัธยฐาน} = \frac{(N + 1)}{2}$$

โดยที่ N เท่ากับจำนวนข้อมูลทั้งหมด

ฐานนิยม (Mode)

ฐานนิยม (Mode) คือ ค่าของคะแนนที่มีความถี่สูงสุด หรือข้อมูลที่ซ้ำกันมากที่สุด ในกลุ่มข้อมูลชุดนั้น

การหาค่าฐานนิยม กรณีข้อมูลไม่มีการแจกแจงความถี่ ให้ดูว่าข้อมูลใดที่ซ้ำกันมากที่สุด
ถือว่าข้อมูลนั้นเป็นฐานนิยม

ตัวอย่าง : จากการสอบเก็บคะแนนวิชาสถิติของนักเรียน 10 คน ได้คะแนนดังนี้

2, 3, 5, 5, 3, 3, 7, 9, 10, 3

ดังนั้น ฐานนิยมของข้อมูลชุดนี้จะมีค่าเท่ากับ .....

ตัวอย่าง : ค่าเฉลี่ย มัธยฐาน ฐานนิยม

จากข้อมูลอายุของคน 7 คน 23, 27, 23, 26, 24, 23, 30 จงหาค่าเฉลี่ย (Mean) มัธยฐาน (Median) และฐานนิยม (Mode) ของข้อมูลเหล่านี้

23 23 23 24 26 27 30

- ค่าเฉลี่ย (Mean) : $\bar{x} = \frac{\sum x}{n} = 25.14$
- มัธยฐาน (Median) $= \frac{n+1}{2} = \frac{7+1}{2} = 4 \rightarrow 24$
- ฐานนิยม (Mode) $\rightarrow 23$

ตัวอย่าง : ค่าเฉลี่ย มัธยฐาน ฐานนิยม

จากข้อมูลน้ำหนัก (หน่วยกิโลกรัม) ของคน 8 คน 57, 45, 55, 46, 55, 60, 45, 39 จงหาค่าเฉลี่ย มัธยฐาน และฐานนิยม ของน้ำหนักของคนเหล่านี้

39 45 45 46 55 55 57 60

- ค่าเฉลี่ย (Mean) : $\bar{x} = \frac{\sum x}{n} = 50.25$
- มัธยฐาน (Median) $= \frac{n+1}{2} = \frac{8+1}{2} = 4.5 \rightarrow \frac{46+55}{2} = 50.5$
- ฐานนิยม (Mode) $\rightarrow 45, 55$ (ไม่มีฐานนิยม)

ทบทวน: ค่าเฉลี่ย (Mean) มัธยฐาน (Median) ฐานนิยม (Mode)

นักเรียนบันทึกเวลาที่ใช้ในการประมวลผลแผนที่จากภาพถ่ายทางอากาศ (Drone) ของคอมพิวเตอร์ 8 เครื่อง ได้เวลาดังนี้ (หน่วย: นาที) :

45, 52, 48, 60, 52, 55, 48, 52

1. จงหาค่าเฉลี่ย (Mean), มัธยฐาน (Median) และฐานนิยม (Mode) ของเวลาที่ใช้ในการประมวลผล

วิธีทำ :

เรียงลำดับข้อมูลจากน้อยไปมาก (N = 8):

`45, 48, 48, 52, 52, 52, 55, 60`

- **หาค่าเฉลี่ย (Mean - $\bar{x}$):**

$$\bar{x} = \frac{45 + 48 + 48 + 52 + 52 + 52 + 55 + 60}{8} = \frac{412}{8} = \mathbf{51.5}\ \text{นาที}$$

- **หามัธยฐาน (Median):**
  - ตำแหน่งมัธยฐาน $= \frac{N+1}{2} = \frac{8+1}{2} = 4.5$ (อยู่ระหว่างตำแหน่งที่ 4 และ 5)
  - ข้อมูลตำแหน่งที่ 4 คือ `52` และตำแหน่งที่ 5 คือ `52`
  - $\text{Median} = \frac{52+52}{2} = \mathbf{52}$ นาที
- **หาฐานนิยม (Mode):**
  - ข้อมูลที่มีความถี่สูงสุด (ปรากฏซ้ำ 3 ครั้ง) คือ **52** นาที

2. ผลกระทบเมื่อมีค่า Outlier (75 นาที):

- ตอบ: ค่าเฉลี่ย (Mean) จะได้รับผลกระทบมากที่สุด
- เหตุผล: ค่าเฉลี่ยนำทุกค่ามาคำนวณ เมื่อมีข้อมูลที่สูงผิดปกติ (Outlier) จะดึงให้ค่าเฉลี่ยสูงขึ้นตาม ในขณะที่มัธยฐานยังคงพิจารณาตำแหน่งเดิม (ตำแหน่งที่ 4.5) และฐานนิยมยังคงพิจารณาความถี่สูงสุดเหมือนเดิม

ตัวอย่างที่ 1:

นักเรียนใช้ วัดระยะระหว่างจุด A และ B จำนวน 9 ครั้ง ได้ผลดังนี้

ครั้งที่	ระยะ (m)
1	100.02
2	99.98
3	100.01
4	100.03
5	99.99
6	100.00
7	100.02
8	99.97
9	100.01

คำถาม:

1. ถ้าต้องรายงาน **ระยะ A–B เพียงค่าเดียว** จะเลือกค่าใด?
2. เพราะเหตุใด?
3. ค่าใดเหมาะที่จะใช้เป็นตัวแทนข้อมูลชุดนี้?

ตอบ:

Mean ≈

Median =

Mode =

“ถ้าวัดระยะหลายครั้ง เราจะเลือกตอบค่าไหน?”

ตัวอย่างที่ 2:

Mean กับ Median ต่างกันเมื่อมีค่าผิดปกติ

นักเรียนใช้ Total Station วัดระยะระหว่างจุด A และ B
จำนวน 9 ครั้ง ได้ผลดังนี้

100.01
99.99
100.02
100.00
99.98
100.01
100.03
99.99
105.80

“มีค่าใดผิดปกติหรือไม่?”

จุดอ่อนของค่าเฉลี่ย (Mean)

ตัวอย่างที่ 1

เหมาะสม (Ideal)

100.02	99.98	100.01	100.03
99.99	100.00	100.02	99.97
100.01			

Mean = 100.0033 m.

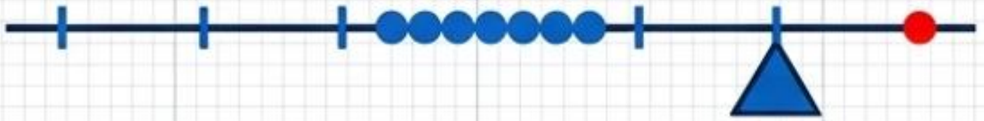


ตัวอย่างที่ 2

จุดหลอกตา (The Trap)

100.01	99.99	100.02	100.00
99.98	100.01	100.03	99.99
105.80			

Mean = 100.6478 m.



Mean จะสูญเสียความน่าเชื่อถือทันที เมื่อชุดข้อมูลมีค่าผิดปกติ (Outlier)

ตัวอย่างที่ 3: กรณีใดควรใช้ Median

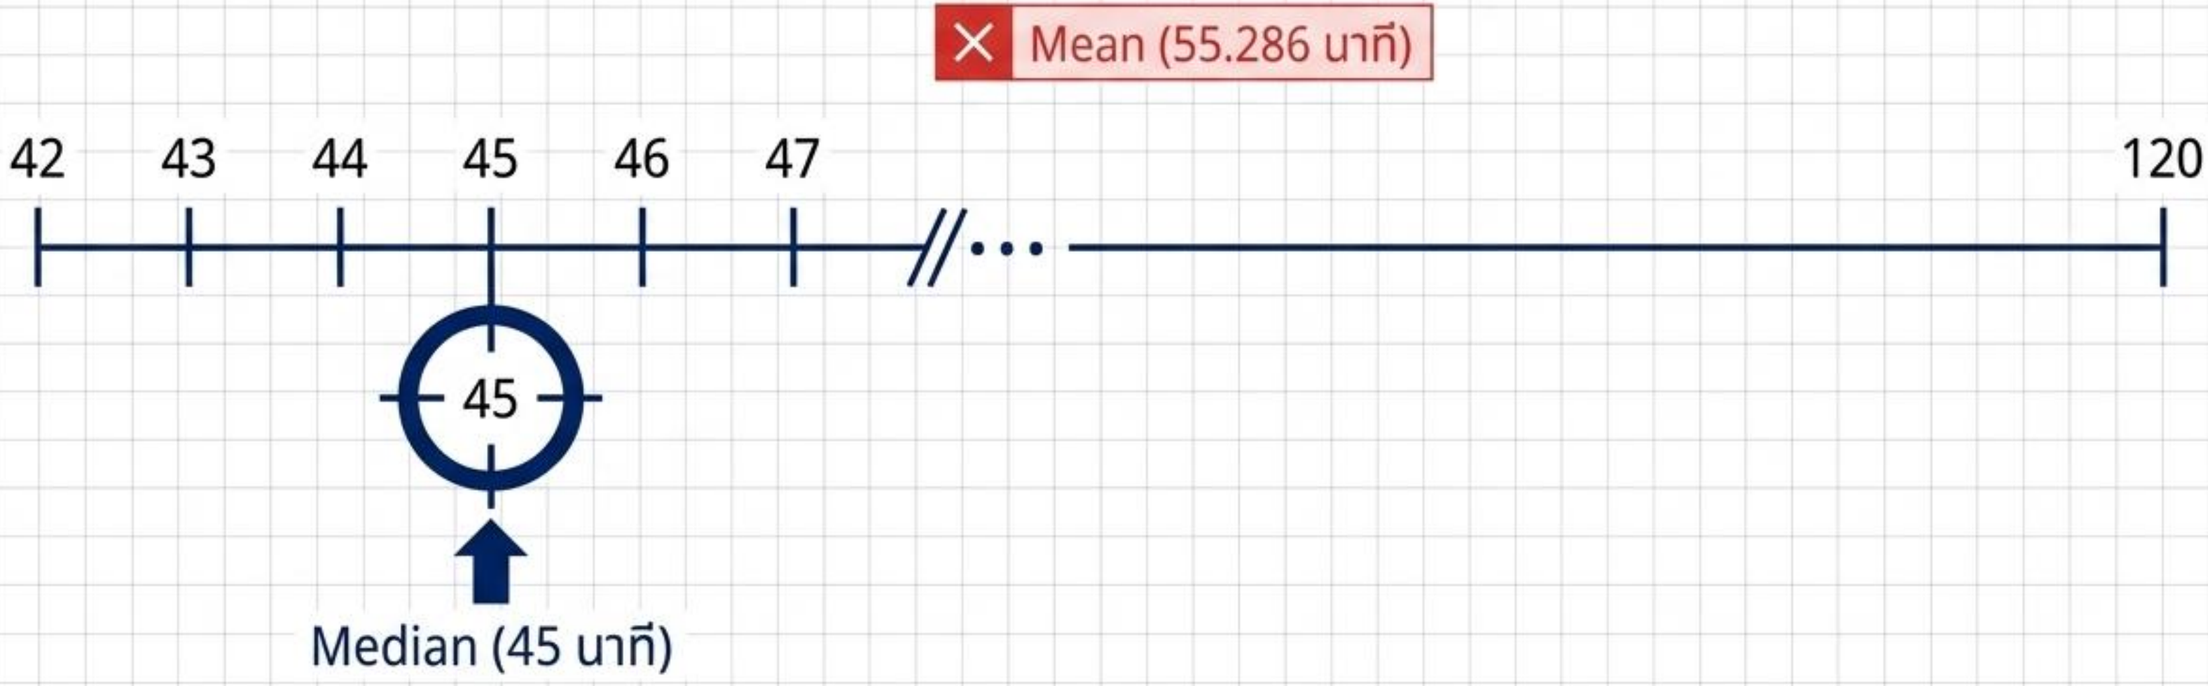
เวลาที่ใช้ในการเดินทางเข้าจุดสำรวจที่ทีมสำรวจบันทึกเวลาเดินทางจากฐานไปยังพื้นที่ปฏิบัติงานเป็นระยะเวลา 7 วัน

วัน	เวลาเดินทาง (นาที)
1	42
2	45
3	44
4	43
5	46
6	47
7	120

“โดยทั่วไปแล้ว ทีมใช้เวลาเดินทางประมาณกี่นาที?”

มัธยฐาน (Median): เสาหลักแห่งความเสถียรเมื่อข้อมูลแกว่ง

เวลาเดินทางเข้าพื้นที่สำรวจ 7 วัน

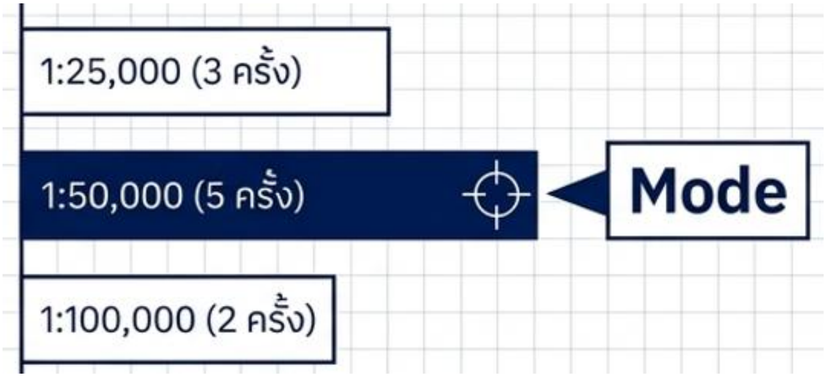


ในกรณีที่มีค่าสุดโต่ง (เช่น รถติดคหนัก 120 นาที)
Median คือตัวแทนที่สะท้อนความเป็นจริงได้ดีกว่า Mean เพราะไม่ถูกดึงด้วยค่าปลายสุด

ตัวอย่างที่ 4: กรณีใด ควรใช้ Mode

รายการข้อมูลแผนที่ ที่มีผู้ขอรับบริการในช่วงหนึ่งสัปดาห์ที่ผ่านมา

แผนที่มาตราส่วน
1:50,000
1:25,000
1:50,000
1:100,000
1:50,000
1:25,000
1:50,000
1:50,000
1:100,000
1:25,000



ดังนั้น Mode ใช้ได้กับข้อมูลเชิงคุณภาพ

“มาตราส่วนใดถูกใช้งานบ่อยที่สุด?”

ตัวอย่างที่ 5: Mode ในงานสำรวจภาคสนาม

ทีมสำรวจบันทึก ประเภทสิ่งกีดขวางที่พบระหว่างการสำรวจแนวเส้นทาง

ต้นไม้
อาคาร
ต้นไม้
เสาไฟ
ต้นไม้
อาคาร
ต้นไม้
ต้นไม้
เสาไฟ
ต้นไม้
อาคาร



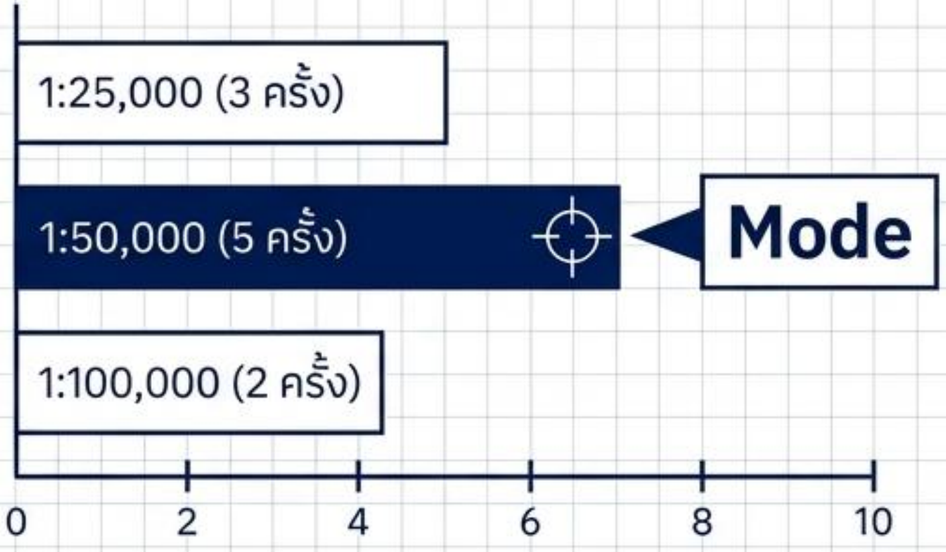
“สิ่งกีดขวางประเภทใดพบมากที่สุด?” ➡ **ต้นไม้**

ดังนั้น Mode ใช้ได้กับข้อมูลเชิงคุณภาพ
ซึ่ง Mean/Median ใช้ไม่ได้ในกรณีทั่วไป

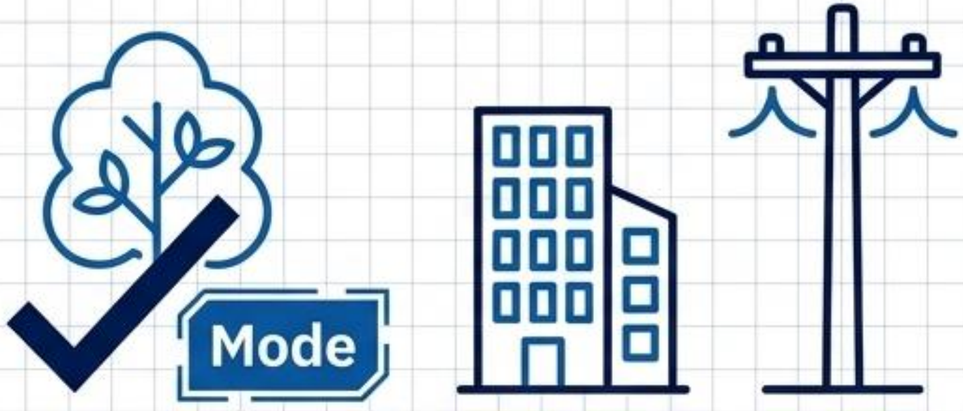
ฐานนิยม (Mode): เครื่องมือเดียวสำหรับข้อมูลเชิงคุณภาพ

เมื่อข้อมูลไม่ใช่ตัวเลขที่ต่อเนื่อง แต่เป็นหมวดหมู่ (Categorical Data) Mean และ Median จะหมดความหมาย

ตัวอย่างที่ 4: มาตราส่วนแผนที่



ตัวอย่างที่ 5: สิ่งกีดขวางภาคสนาม



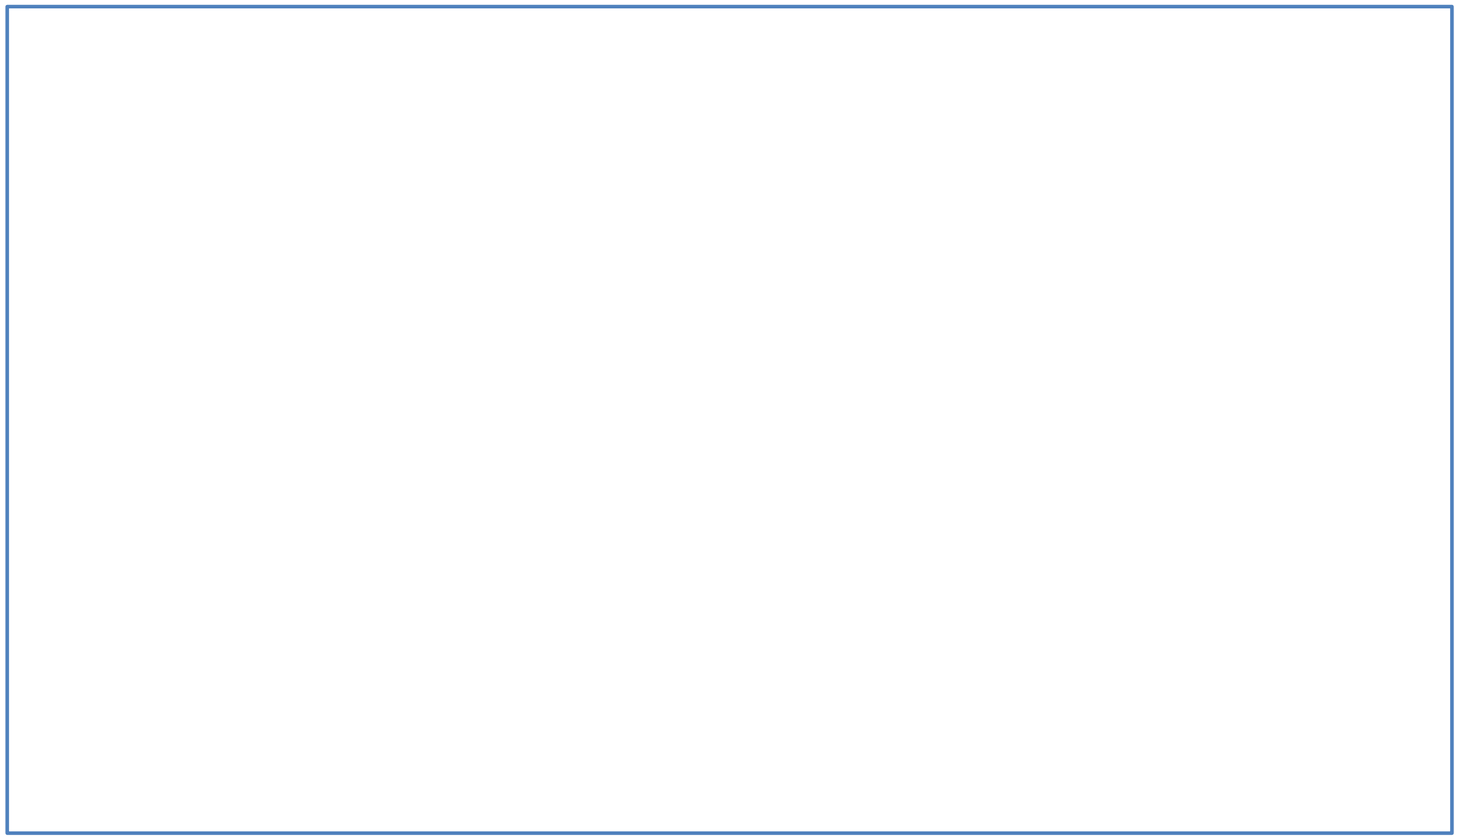
สิ่งกีดขวางที่พบมากที่สุด = ต้นไม้

ตัวอย่างที่ 6: “ค่าไหนเป็นตัวแทนที่ดีที่สุด?”

มีผลการวัดระดับ (Elevation) ของจุดหนึ่ง 11 ครั้ง (หน่วย : เมตร)

50.02
50.01
49.99
50.03
50.00
50.01
49.98
50.02
50.00
50.01
52.40

จงคำนวณ : Mean / Median / Mode



ถ้าต้องเลือกหนึ่งค่าเพื่อเป็นตัวแทนของข้อมูลชุดนี้ ควรจะเลือกค่าใด เพราะเหตุใด?”

ตัวอย่างที่ 7:

นักเรียนจำนวน 3 กลุ่ม วัดระยะ A–B ได้ดังนี้ (หน่วย: เมตร)

กลุ่มที่ 1

99.98, 99.99, 100.00, 100.01, 100.02

กลุ่มที่ 2

99.98, 99.99, 100.00, 100.01, **105.00**

กลุ่มที่ 3

99.50, 99.50, 99.50, 99.50, 99.50

คำถาม:

1 : Mean ของแต่ละชุดเป็นเท่าไร?

2 : Median ของแต่ละชุดเป็นเท่าไร?

3 : Mode ของแต่ละชุดเป็นเท่าไร?

4 : ถ้าต้องเลือกหนึ่งค่าเพื่อเป็นตัวแทนข้อมูลควรเลือกค่าใด?

5 : ทำไมค่าที่เลือกถึงเหมาะสม?

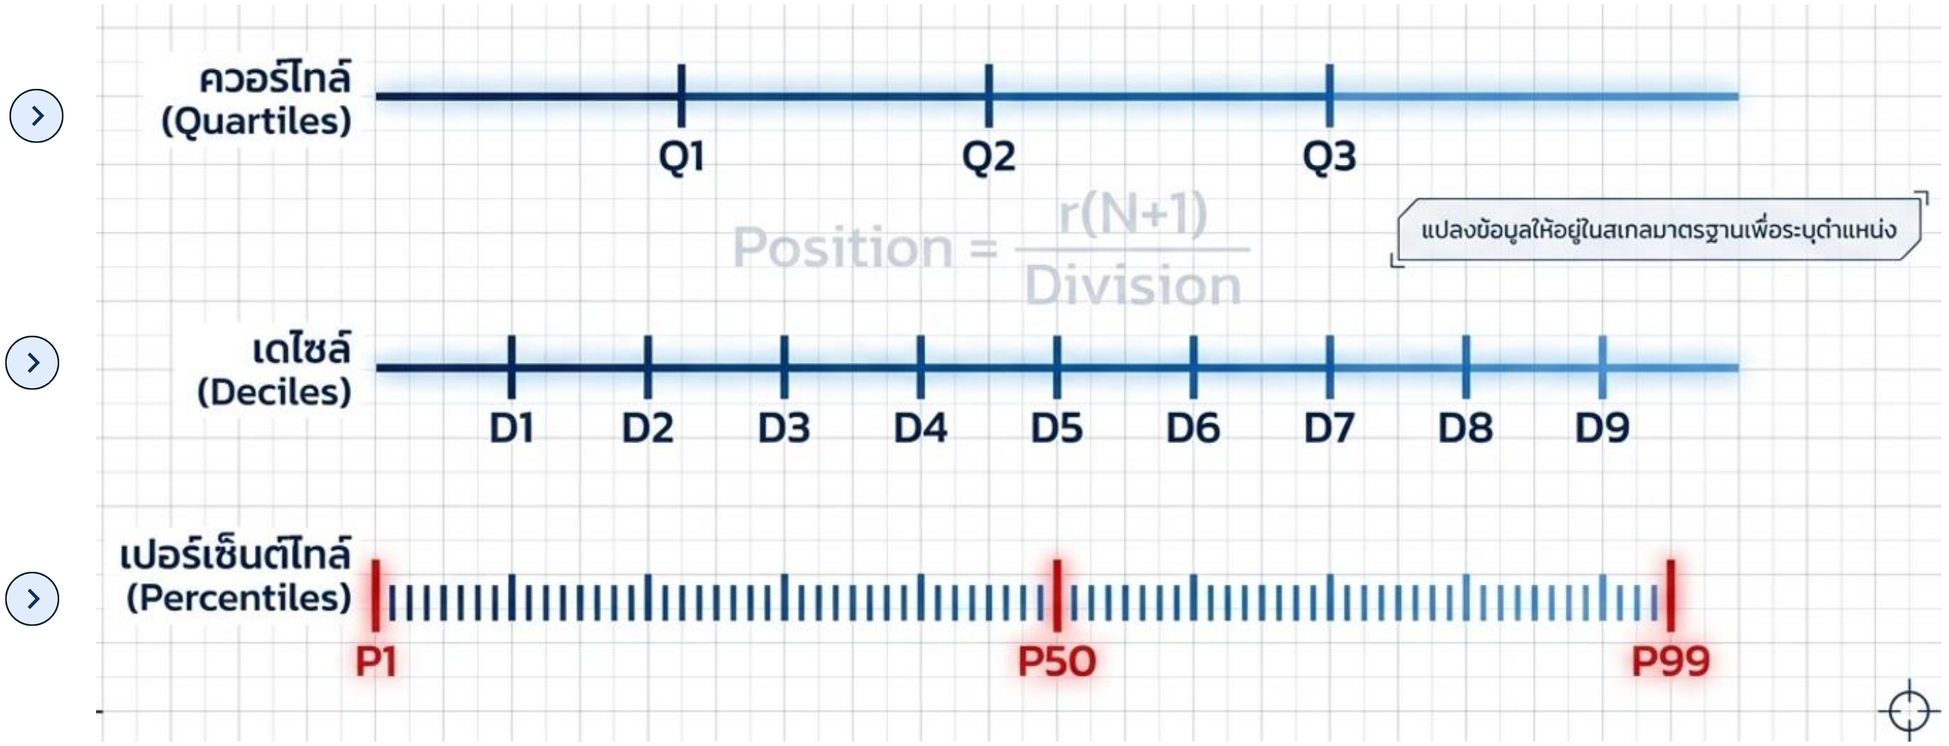
Synthesis: ตารางตัดสินใจเลือกใช้ค่ากลางในงานสำรวจ

สถานการณ์ A	สถานการณ์ B	สถานการณ์ C
ผลการวัดระยะ 10 ครั้ง (99.98 – 100.03)	เวลาเดินทางไปพื้นที่ (42, 44, ..., 120 นาที)	ประเภทหมุดหลักฐาน (คอนกรีต, เหล็ก, พลาสติก)
ข้อมูลเกาะกลุ่ม สมมาตร ไม่มีค่าโดด	มีค่าผิดปกติที่สูง/ต่ำสุดโต่ง (Outlier)	ข้อมูลเชิงคุณภาพ นับความถี่
➡ เลือก Mean	➡ เลือก Median	➡ เลือก Mode
สะท้อนค่าเฉลี่ยทางคณิตศาสตร์ได้ดีที่สุด	ทนทานต่อค่าปลายสุด	พิจารณาจากค่าที่เกิดซ้ำมากที่สุด



เราไม่ได้เรียนเพื่อท่องสูตร 3 สูตร แต่เรียนเพื่อรู้ว่า
สถานการณ์แบบไหน ควรหยิบเครื่องมือใดมาใช้

การระบุตำแหน่งของข้อมูล



การระบุตำแหน่งของข้อมูล

การวัดตำแหน่งเป็นการแปลงข้อมูลแต่ละชุดให้อยู่ในลักษณะเดียวกันเพื่อประโยชน์ในการเปรียบเทียบข้อมูลระหว่างข้อมูลคนละชุดกัน การแปลงข้อมูลมีลักษณะเป็นการแบ่งชุดข้อมูลออกเป็นส่วนย่อยๆ โดยมีทั้งการแบ่งออกเป็น 4, 10 และ 100 ส่วน

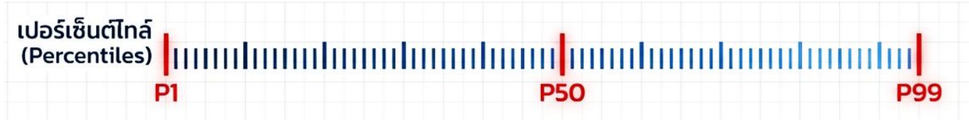
- การวัดตำแหน่งที่แบ่งข้อมูลออกเป็น **4 ส่วน** คือ ควอร์ไทล์ (Quartiles)



- การวัดตำแหน่งที่แบ่งข้อมูลออกเป็น **10 ส่วน** คือ เดไซล์ (Deciles)



- การวัดตำแหน่งที่แบ่งข้อมูลลออกเป็น **100 ส่วน** คือ เปอร์เซ็นไทล์ (Percentiles)



การหาค่าของ ควอไทล์ เดไซล์ เปอร์เซ็นไทล์

1. จัดเรียงลำดับคะแนนของข้อมูลจาก**น้อย -> มาก**
2. หาตำแหน่งของข้อมูลโดยใช้สูตร

- ตำแหน่ง Q_r = $\frac{r(N+1)}{4}$

- ตำแหน่ง D_r = $\frac{r(N+1)}{10}$

- ตำแหน่ง P_r = $\frac{r(N+1)}{100}$

$$\text{Position} = \frac{r(N+1)}{\text{Division}}$$

แปลงข้อมูลให้อยู่ในสเกลมาตรฐานเพื่อระบุตำแหน่ง

แบบฝึกหัด : ควอร์ไทล์ เดไซล์ เปอร์เซ็นต์ไทล์

1. คะแนนสอบของนักเรียน 10 คน คือ 58, 70, 62, 48, 56, 68, 76, 80, 90, 92

จงหา Med, Q_3, D_7, P_{45}

แบบฝึกหัด : ควอร์ไทล์ เดไซล์ เปอร์เซ็นต์ไทล์



2. จากข้อมูลความสูงของนักเรียน 6 คน คือ 156, 152, 157, 150, 156, 159

จงหา P_{40}, Q_2, D_7

แบบฝึกหัด : ควอร์ไทล์ เดไซล์ เปอร์เซ็นต์ไทล์



➢ **จากข้อมูลคะแนนสอบวิชาคณิตศาสตร์ ซึ่งเรียงลำดับจากน้อยไปมาก ดังต่อไปนี้**

3 5 X 8 10 11 12 13 Y 17 20

ถ้าควอไทล์ที่ 1 มีค่าเท่ากับ 7 คะแนน แล้วค่าเฉลี่ยเลขคณิตเท่ากับ 11
จงหาเดไซน์ที่ 5 และเปอร์เซ็นต์ไทล์ที่ 80

แบบฝึกหัด : ควอร์ไทล์ เดไซล์ เปอร์เซ็นต์ไทล์

ข้อมูลชุดหนึ่งเรียงจากน้อยไปหามากดังนี้ $5 , 10 , 12 , 20 , x , 26 , 30 , 42 , 47 , y$ ถ้าข้อมูลชุดนี้มีพิสัยเท่ากับ 45 และค่าเฉลี่ยเลขคณิตเท่ากับ 26.4 แล้ว ควอไทล์ที่สองเท่ากับเท่าใด

Percentile ในมิติของการวางแผนงานสำรวจ

ทีมสำรวจบันทึกเวลาที่ใช้ในการตั้งกล้อง Total Station ต่อหนึ่งจุด

P25	= 8 นาที
P50	= 10 นาที (Median)
P75	= 13 นาที
P90	= 18 นาที
P95	= 22 นาที



ถ้าต้องการเวลาเฉลี่ยโดยทั่วไป ที่แบ่งครึ่งทีมงานพอดี ควรประเมินเวลาที่จุดใด?

คำตอบ: P50 (Median) = 10 นาที

แต่ถ้าผู้จัดการโครงการต้องการวางแผนงานให้เสร็จชัวร์ 90% ของจุดทั้งหมด ต้องเผื่อเวลาไว้ที่เท่าไหร่?

คำตอบ: มองไปที่ P90 = 18 นาที

(นี่คือการประยุกต์ใช้ Percentile เพื่อบริหารความเสี่ยง)

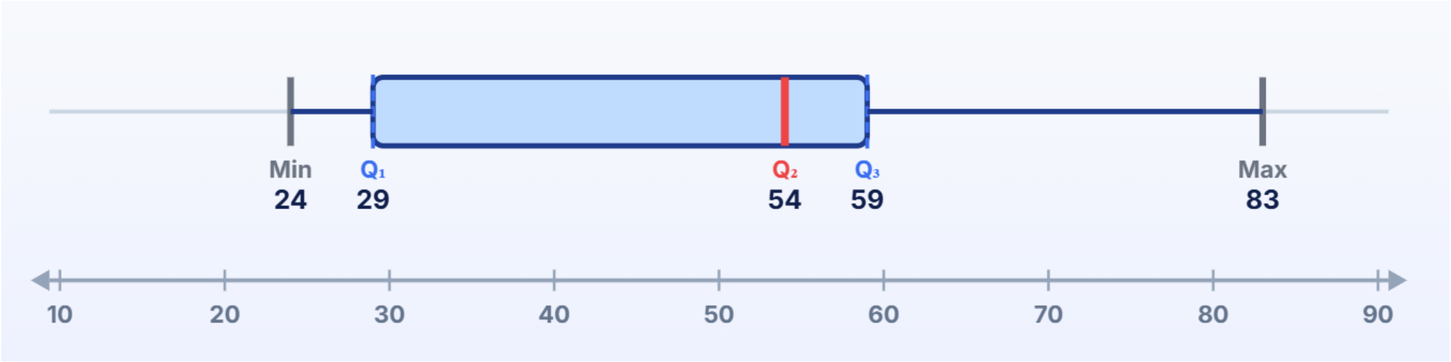
ตัวอย่าง การสร้างแผนภาพกล่อง :

ข้อมูล (ยังไม่เรียง): 83, 54, 24, 29, 56, 59, 52

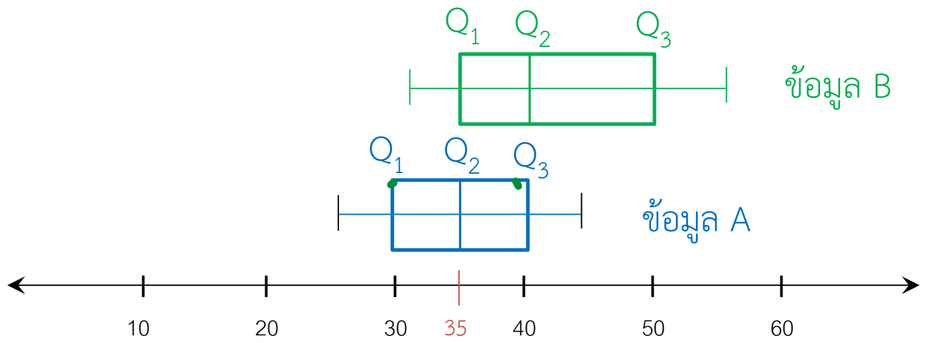
ข้อมูลเรียงแล้ว · N = 7

1	2	3	4	5	6	7
24	29	52	54	56	59	83

- หา Min และ Max : Min = 24 , Max = 83
- หา MEDIAN (Q2) : Q2 -> ตัวที่ 4 = 54
- หา Q_1 และ Q_3 : Q1 = 29 , Q3 = 59
- ตรวจสอบ f_L และ f_U



ตัวอย่างโจทย์เกี่ยวกับ Box Plot



จงตอบคำถามต่อไปนี้ :

1. ข้อมูล A สมมาตร?
2. ข้อมูล B เบ้ขวา
3. 25% ของกลุ่ม A ใช้เวลา 30 นาที
4. 25% ของกลุ่ม B ใช้เวลา 35 นาที
5. 75% ของกลุ่ม B ใช้เวลา 40 นาที
6. 50% ของกลุ่ม A ใช้เวลา 30 นาที
7. A กระจายตัวมากกว่า B

ตัวอย่างที่ 1:

ชุดสำรวจวัดระยะจากจุด A ⟶ B ด้วย Total Station จำนวน 15 ครั้ง ได้ผลดังนี้ (หน่วย: เมตร)

100.01, 99.98, 100.02, 100.00, 100.03, 99.99, 100.01, 100.02, 99.97, 100.00, 100.04, 100.01, 99.99, 100.02, **100.35**

วิธีทำ : 1) เรียงข้อมูลจากน้อยไปมาก

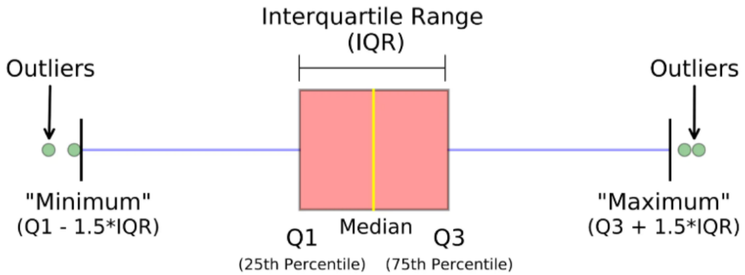
99.97
99.98
99.99
99.99
100.00
100.00
100.01
100.01
100.01
100.02
100.02
100.02
100.03
100.04
100.35

2) . Box Plot จะ

- จะสรุปข้อมูลออกมาเป็น 5 ค่าหลัก
- และที่สามารถช่วยมองเห็น **Outlier** ได้

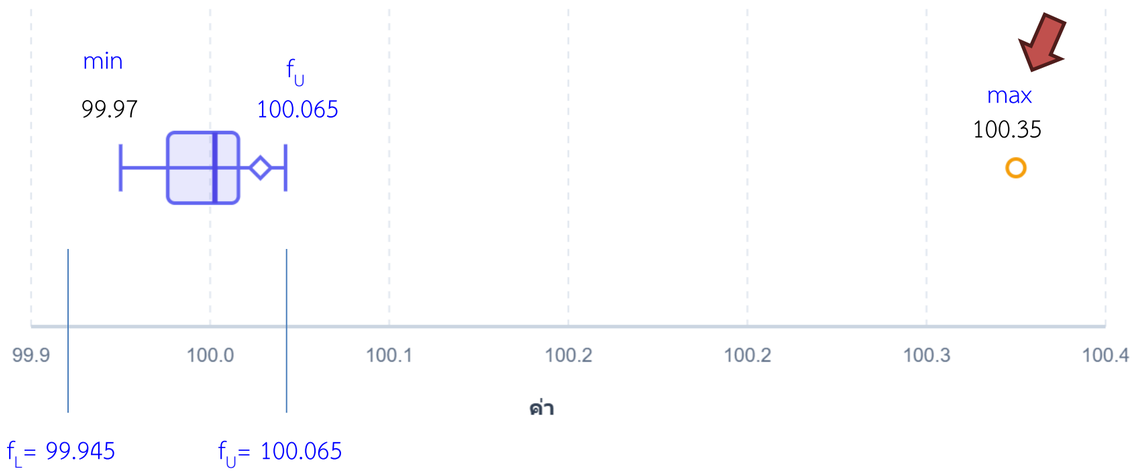
5 ค่าหลัก (Five-number summary) :

1. Minimum = 99.97
2. Q1 — First Quartile = 99.99
3. Median — Q2 = 100.01
4. Q3 — Third Quartile = 100.02
5. Maximum = 100.35



3) หาขอบเขตบน และขอบเขตล่าง

- f_L
- f_U



การวิเคราะห์จาก Box Plot :

นำมาวิเคราะห์ต่อ ว่า “100.35 m เกิดจากอะไร?”

เช่น

- อ่านค่าผิดหรือไม่?
- บันทึกข้อมูลผิดหรือไม่?
- ตั้งเครื่องผิดหรือไม่?
- มีสิ่งกีดขวาง?
- มีปัญหากับเป้าหมาย?
- เป็น observation ที่มีความผิดปกติจริงหรือไม่?

Box Plot สามารถบอกได้ว่า

ข้อมูลมีลักษณะผิดปกติ แต่ไม่ได้บอกว่า *ข้อมูลนั้นผิดแน่นอน*

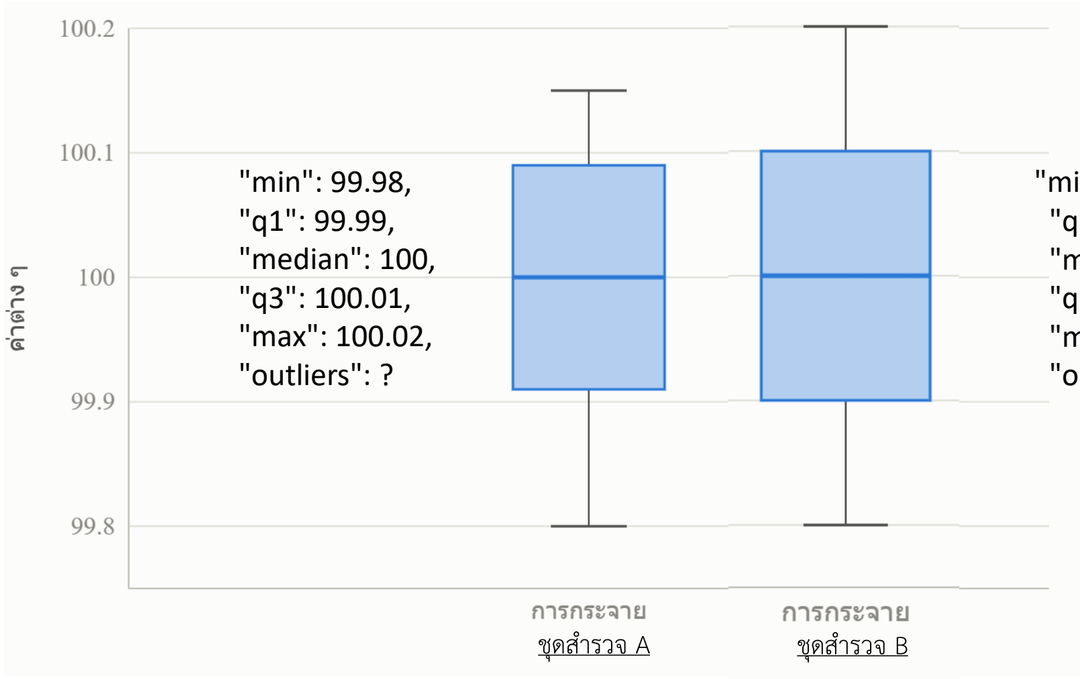
ตัวอย่างที่ 2:

เปรียบเทียบความสม่ำเสมอของการวัดระยะของ 2 ชุดสำรวจ

สมมติให้ ชุดสำรวจ A และชุดสำรวจ B วัดระยะ A–B จำนวน 15 ครั้ง

ชุดสำรวจ A	ชุดสำรวจ B
99.98	99.80
99.99	100.10
100.00	99.95
100.01	100.05
100.02	99.90
99.99	100.15
100.00	99.85
100.01	100.00
100.02	100.10
100.00	99.92
99.98	100.08
100.01	99.88
100.02	100.12
99.99	99.97
100.00	100.03

สร้าง Box Plot 2 กล่อง

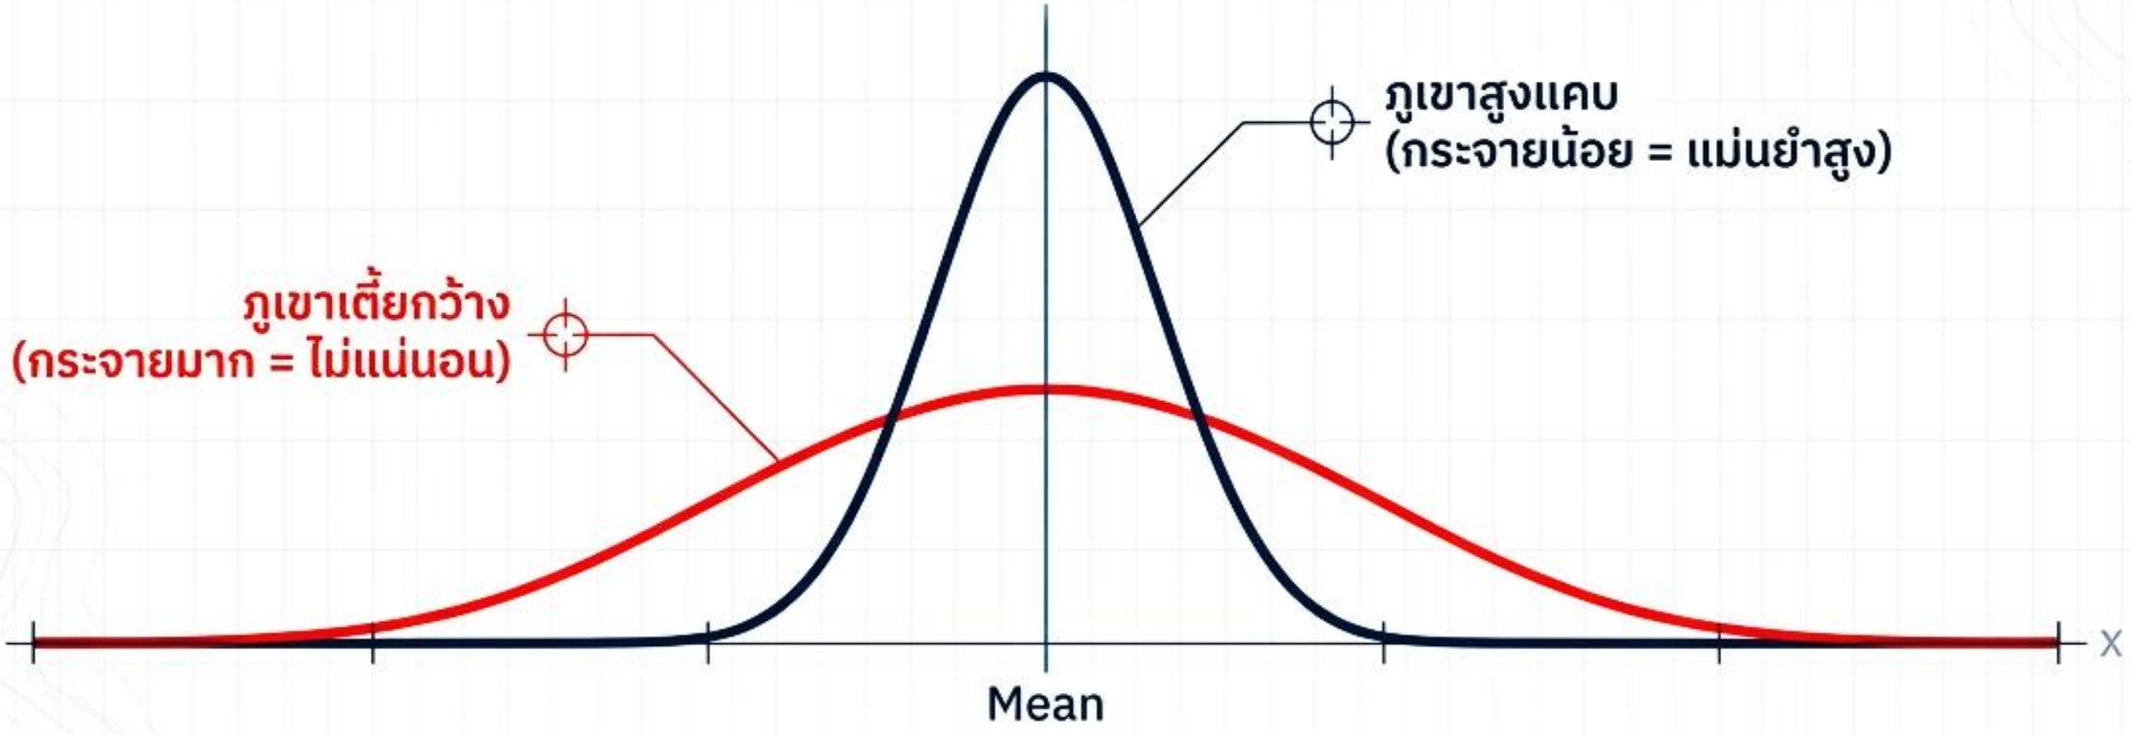


“ถ้าค่าเฉลี่ยของทั้งสองชุดใกล้เคียงกัน เราจะบอกได้อย่างไรว่าชุดไหนวัดได้สม่ำเสมอกว่า?”

การวัดการกระจายของข้อมูล

- พิสัย
- ส่วนเบี่ยงเบนมาตรฐาน
- ความแปรปรวน
- สัมประสิทธิ์การแปรผัน

มีค่ากลางแล้ว ทำไมต้องดูการกระจาย ?
คำตอบคือ: ข้อมูลที่ดีจะต้องมีการกระจายต่ำสุด



การวัดการกระจายคือตัวการันตีความแม่นยำ (Precision)

การวัดการกระจายของข้อมูล (Measures of Dispersion)

วิธีการวัดการกระจายของข้อมูล แบ่งได้เป็น 2 วิธี คือ

1. การวัดการกระจายสัมบูรณ์ (Absolute Variation) เป็นการวัดการกระจายของข้อมูลเพียงชุดเดียว ว่าข้อมูลมีความแตกต่างมากหรือน้อย ตัวสถิติที่นิยมใช้ ได้แก่

- พิสัย (Range)
- ส่วนเบี่ยงเบนมาตรฐาน (Standard Deviation)
- ความแปรปรวน (Variance)

2. การวัดการกระจายสัมพัทธ์ (Relative Variation) เป็นการวัดการกระจายของข้อมูลที่มากกว่าหนึ่งชุด เพื่อเปรียบเทียบการกระจายของข้อมูลเหล่านั้น ตัวสถิติที่นิยมใช้ ได้แก่

- สัมประสิทธิ์การแปรผัน (Coefficient of Variation)

1. การวัดการกระจายสัมบูรณ์ (Absolute Variation)

- **พิสัย** เป็นการวัดการกระจายที่ง่ายที่สุด เป็นการหาความแตกต่างของข้อมูลสูงสุดและต่ำสุดของกลุ่ม

  พิสัย = ค่าสูงสุดของข้อมูล – ค่าต่ำสุดของข้อมูล

ตัวอย่าง จงหาพิสัยของชุดข้อมูลทั้ง 3 ชุด

A:	10	12	15	18	20
B:	2	8	15	22	28
C:	15	15	15	15	15

ข้อมูลใดมีการกระจายมากกว่ากัน ?

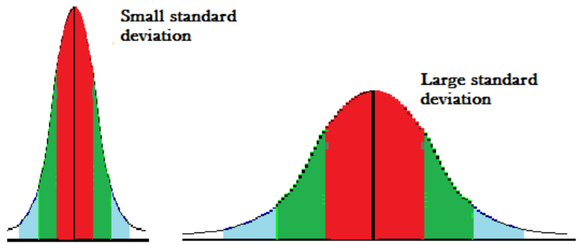
- **ส่วนเบี่ยงเบนมาตรฐาน (Standard Deviation)**

  - ส่วนเบี่ยงเบนมาตรฐานของตัวอย่าง (Sample Standard Deviation)

$$s = \sqrt{\frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1}}$$

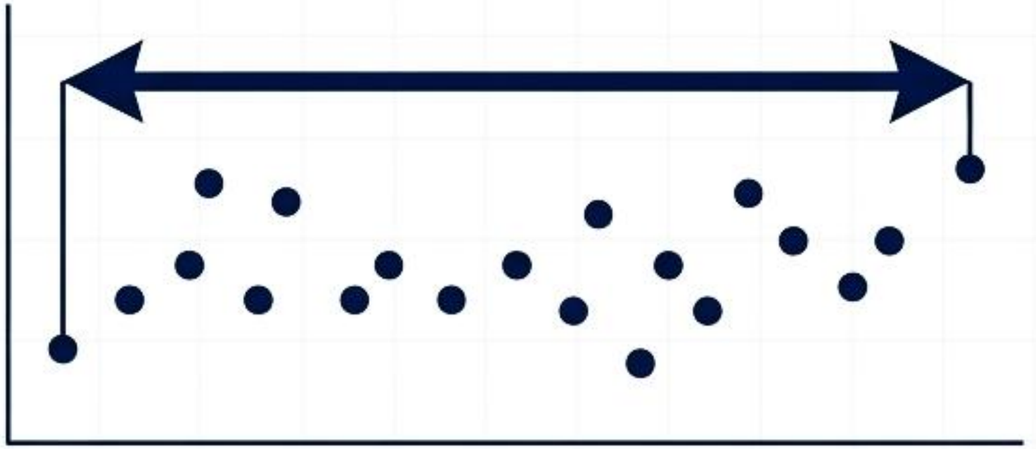
  - ส่วนเบี่ยงเบนมาตรฐานของประชากร (Population Standard Deviation)

$$\sigma = \sqrt{\frac{\sum_{i=1}^{N}(x_i - \mu)^2}{N}}$$



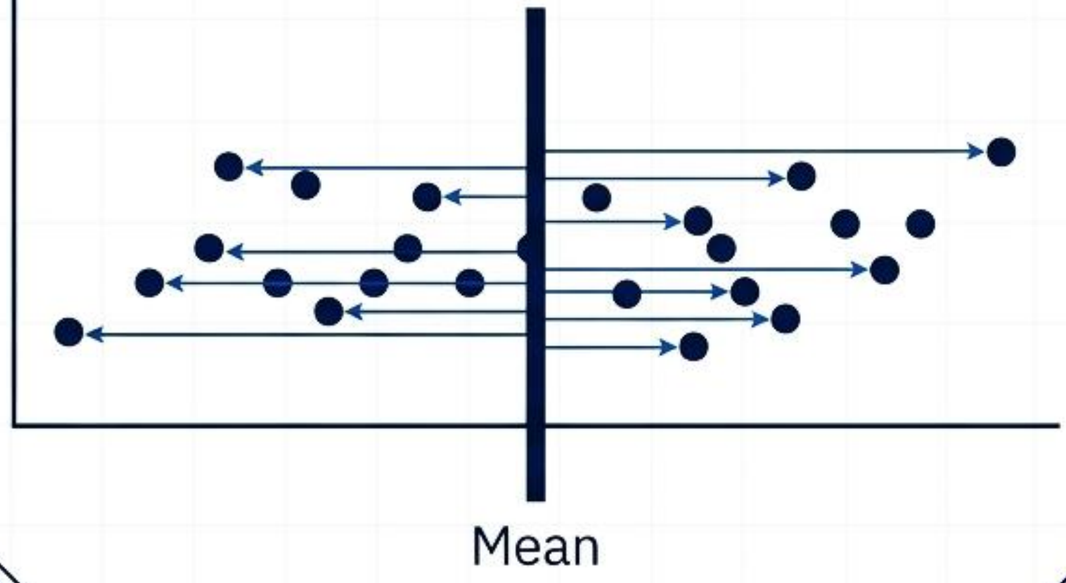
การวัดการกระจายสัมบูรณ์: หยาบ vs. ละเอียด

พิสัย (Range)



วัดแบบ**หยาบ** (Max - Min). สนใจแค่ขอบเขตหัวท้าย ทิ้งข้อมูลตรงกลางทั้งหมด

ส่วนเบี่ยงเบนมาตรฐาน (Standard Deviation - SD)



วัดแบบละเอียด ใช้อธิบายความคลาดเคลื่อนร่วมกับค่าเฉลี่ย (Mean) เสมอ

$$s = \sqrt{\frac{\sum(x_i - \bar{x})^2}{n-1}}$$

- **ค่าความแปรปรวน (Variance)**

ค่าความแปรปรวนจะเป็นค่าของส่วนเบี่ยงเบนมาตรฐานยกกำลังสอง

- ความแปรปรวนของตัวอย่าง (Sample Variance)

$$s^2 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1}$$

- ความแปรปรวนของประชากร (population variance)

$$\sigma^2 = \frac{\sum_{i=1}^{N}(x_i - \mu)^2}{N}$$

2. การวัดการกระจายสัมพัทธ์ (Relative Variation)

- **สัมประสิทธิ์การแปรผัน (Coefficient of Variation : C.V.)**

- สัมประสิทธิ์การแปรผันของตัวอย่าง (Sample standard deviation)

$$cv = \frac{s}{\bar{x}} \times 100\%$$

- สัมประสิทธิ์การแปรผันของประชากร (population standard deviation)

$$cv = \frac{\sigma}{\mu} \times 100\%$$

โดย

s คือ ส่วนเบี่ยงเบนมาตรฐานของตัวอย่าง

σ คือ ส่วนเบี่ยงเบนมาตรฐานของประชากร

การวัดการกระจายสัมพัทธ์ (Relative Variation)

สัมประสิทธิ์การแปรผัน (C.V.): เมื่อต้องเปรียบเทียบข้อมูลคนละสเกล

PROBLEM

ถ้าต้องการเทียบการกระจายของข้อมูล 2 ชุดที่ค่าเฉลี่ยต่างกันมาก (เช่น ข้อมูล A ค่าเฉลี่ย 15 vs ข้อมูล B ค่าเฉลี่ย 45) เราไม่สามารถใช้ SD เทียบกันตรงๆ ได้

SOLUTION

การวัดการกระจายสัมพัทธ์ (Relative Variation)

$$C.V. = \left(\frac{S}{\bar{x}}\right) \times 100\%$$

แปลงค่าความคลาดเคลื่อนให้เป็นเปอร์เซ็นต์ เพื่อสร้างมาตรฐานเดียวกันและหาว่ากลุ่มใดเสถียรที่สุด

แบบฝึกหัด : การกระจายตัวของข้อมูล

3. จากข้อมูลที่กำหนดให้

ชุด A :	5	10	15	20	25
ชุด B :	15	30	45	60	50

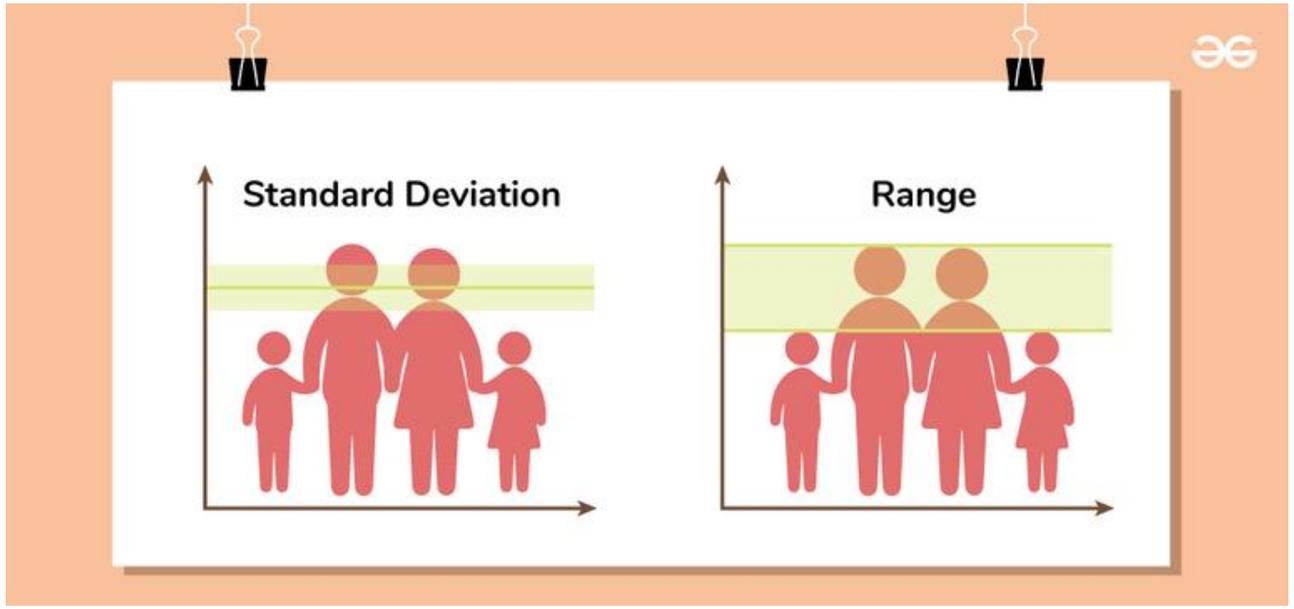
3.1) จงหาสัมประสิทธิ์การแปรผัน ข้อมูลประชากร ชุด A และ ชุด B

3.2) ข้อมูลชุด A มีการกระจายตัวมากกว่าหรือน้อยกว่าข้อมูลชุด B

3.3) ข้อมูลชุดใดดีกว่ากัน

>>>>> สรุป : การเลือกใช้วิธีวัดการกระจาย <<<<<

1. กรณีต้องการดูการกระจายแบบหยาบๆ ใช้**ค่าพิสัย**
2. กรณีวัดแนวโน้มเข้าสู่ส่วนกลางโดยใช้ค่าเฉลี่ย ใช้**ส่วนเบี่ยงเบนมาตรฐาน**ในการวัดการกระจาย

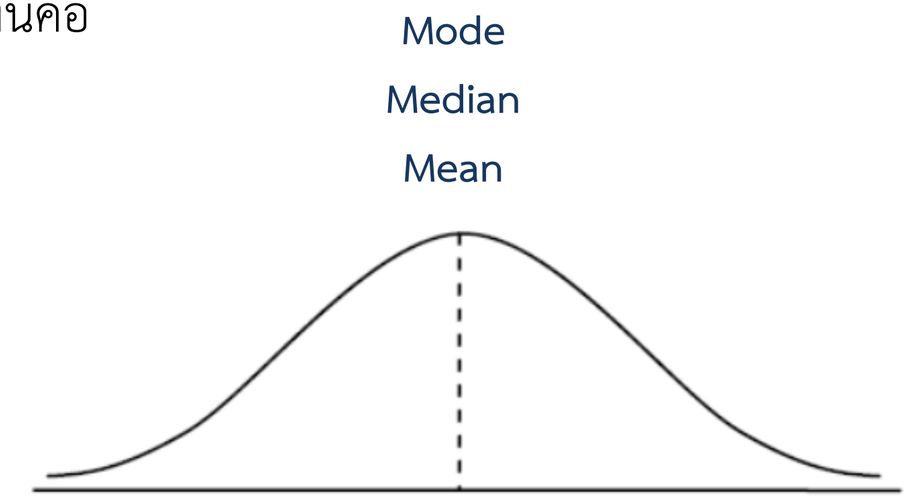


>>>>> ความสัมพันธ์ระหว่างค่ากลางทั้งสามชนิด (ค่าเฉลี่ย มัธยฐาน ฐานนิยม) <<<<<

จากการแจกแจงความถี่ของข้อมูล เมื่อนำมาเขียน**กราฟเส้นโค้งความถี่** ในทางสถิติจะสนใจโค้งความถี่ 2 ชนิด คือ **โค้งปกติ (Normal Curve)** และ **โค้งเบ้ (Skews Curve)** โดยมีค่าที่นำมาใช้พิจารณาว่าเป็นโค้งปกติหรือโค้งเบ้ คือ ค่าเฉลี่ย (Mean) ค่ามัธยฐาน (Median) และ ค่าฐานนิยม (Mode) ดังนี้

- โค้งปกติ (Normal Curve)

เป็นโค้งที่มีลักษณะสมมาตรโดยมีค่าค่าเฉลี่ย (Mean) ค่าฐานนิยม (Mode) และค่ามัธยฐาน (Median) เท่ากัน ดังนั้น จึงอยู่ในตำแหน่งเดียวกันของกราฟ ดังภาพ แกนนอนนิยมแสดงในรูปค่ามาตรฐานที่เรียกว่าคะแนนมาตรฐาน ซึ่งจะมาจากค่าเดิมของข้อมูลดังนี้คือ

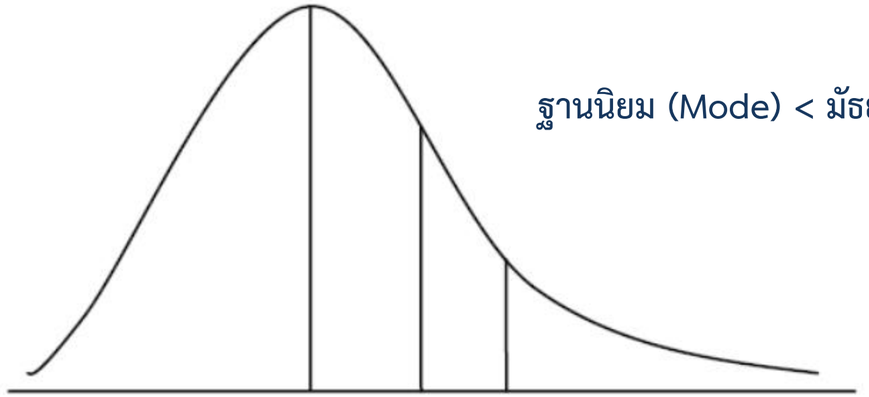


เส้นโค้งปกติ หรือ รูประฆังคว่ำ

- [โค้งเบ้ (Skews Curve)]

เป็นโค้งที่มีลักษณะไม่สมมาตร ค่าเฉลี่ย (Mean) ค่าฐานนิยม (Mode) และค่ามัธยฐาน (Median) แตกต่างกัน ดังนั้นจึงอยู่ในตำแหน่งแตกต่างกัน ดังภาพต่อไปนี้

1) เส้นโค้งเบ้ทางขวาหรือทางบวก เป็นลักษณะของเส้นโค้งที่มีความชันน้อยอยู่ทางด้านขวา ค่าเฉลี่ยเลขคณิตมีค่ามากที่สุด รองลงมาเป็นมัธยฐาน และฐานนิยมมีค่าน้อยที่สุด

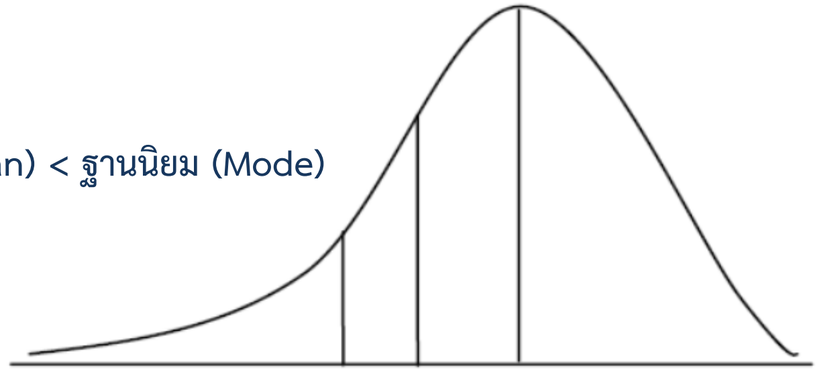


ฐานนิยม (Mode) < มัธยฐาน (Median) < ค่าเฉลี่ยเลขคณิต (Mean)

เส้นโค้งเบ้ทางขวาหรือทางบวก

2) เส้นโค้งเบ้ทางซ้ายหรือทางลบ เป็นลักษณะของเส้นโค้งที่มีความชันน้อยอยู่ทางด้านซ้าย ฐานนิยมมีค่ามากที่สุด รองลงมาเป็นมัธยฐาน และค่าเฉลี่ยเลขคณิตมีค่าน้อยที่สุด

ค่าเฉลี่ยเลขคณิต (Mean) < มัธยฐาน (Median) < ฐานนิยม (Mode)



Mean Median Mode

เส้นโค้งเบ้ทางซ้ายหรือทางลบ

การเปรียบเทียบข้อมูล 2 ชุดจากเส้นโค้งปกติ

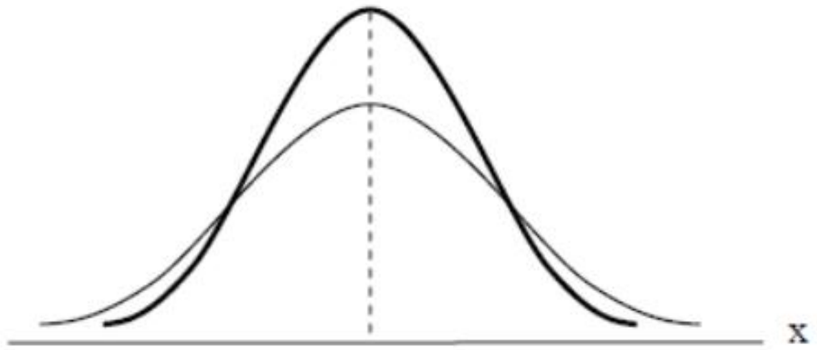
เมื่อพิจารณาลักษณะของโค้งปกติได้จากพารามิเตอร์ μ และ σ ซึ่งมีค่าแตกต่างกันไป
ถ้าค่า σ มีค่ามากโค้งปกติจะค่อนข้างลาด แต่ถ้าค่า σ มีค่าน้อยเส้นโค้งจะค่อนข้างโด่ง ดังแสดงต่อไปนี้

กำหนดให้ ——— แทน ข้อมูลชุดที่ 1

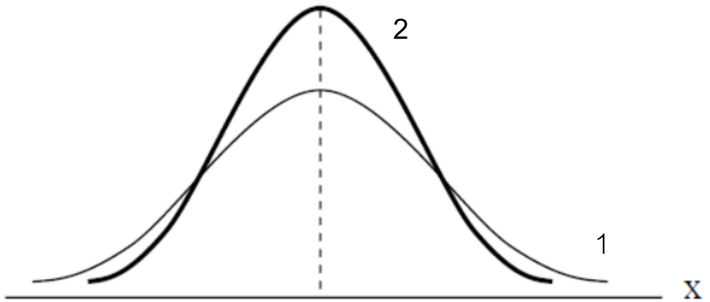
——— แทน ข้อมูลชุดที่ 2

μ แทน ค่าเฉลี่ยของข้อมูล

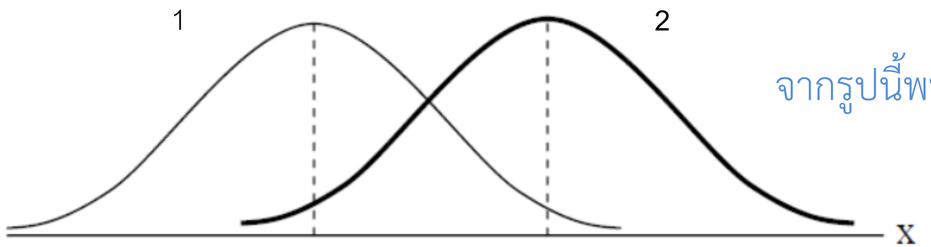
σ แทน ส่วนเบี่ยงเบนมาตรฐานของข้อมูล



1. เส้นโค้งปกติที่มี $\mu_1 = \mu_2$ แต่ $\sigma_1 \neq \sigma_2$ โดยที่ $\sigma_1 > \sigma_2$ ลักษณะของเส้นโค้งทั้งสองจะแตกต่างกัน
เส้นโค้งปกติที่มีส่วนเบี่ยงเบนมาตรฐานมากกว่าจะมีลักษณะแบนและลาดต่ำกว่าเส้นโค้งปกติที่มีส่วนเบี่ยงเบนมาตรฐานน้อยกว่า
โดยตำแหน่งของจุดยอดอยู่ที่เดียวกัน

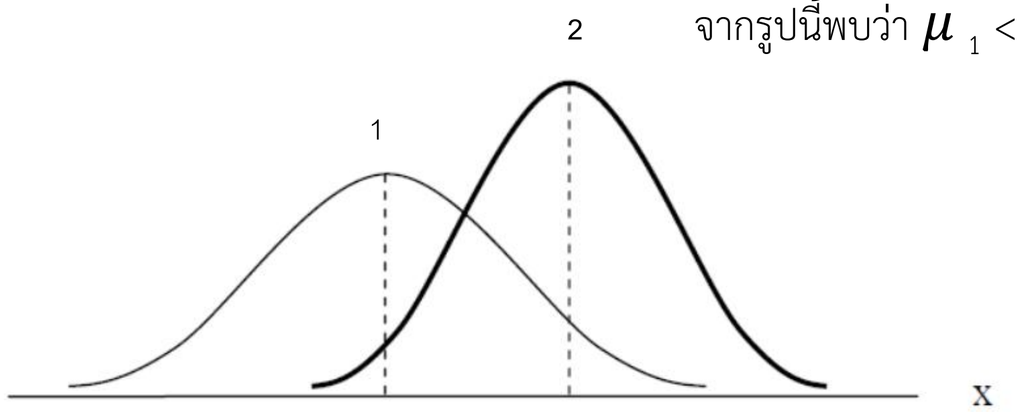


2. เส้นโค้งปกติที่ $\mu_1 \neq \mu_2$ แต่ $\sigma_1 = \sigma_2$

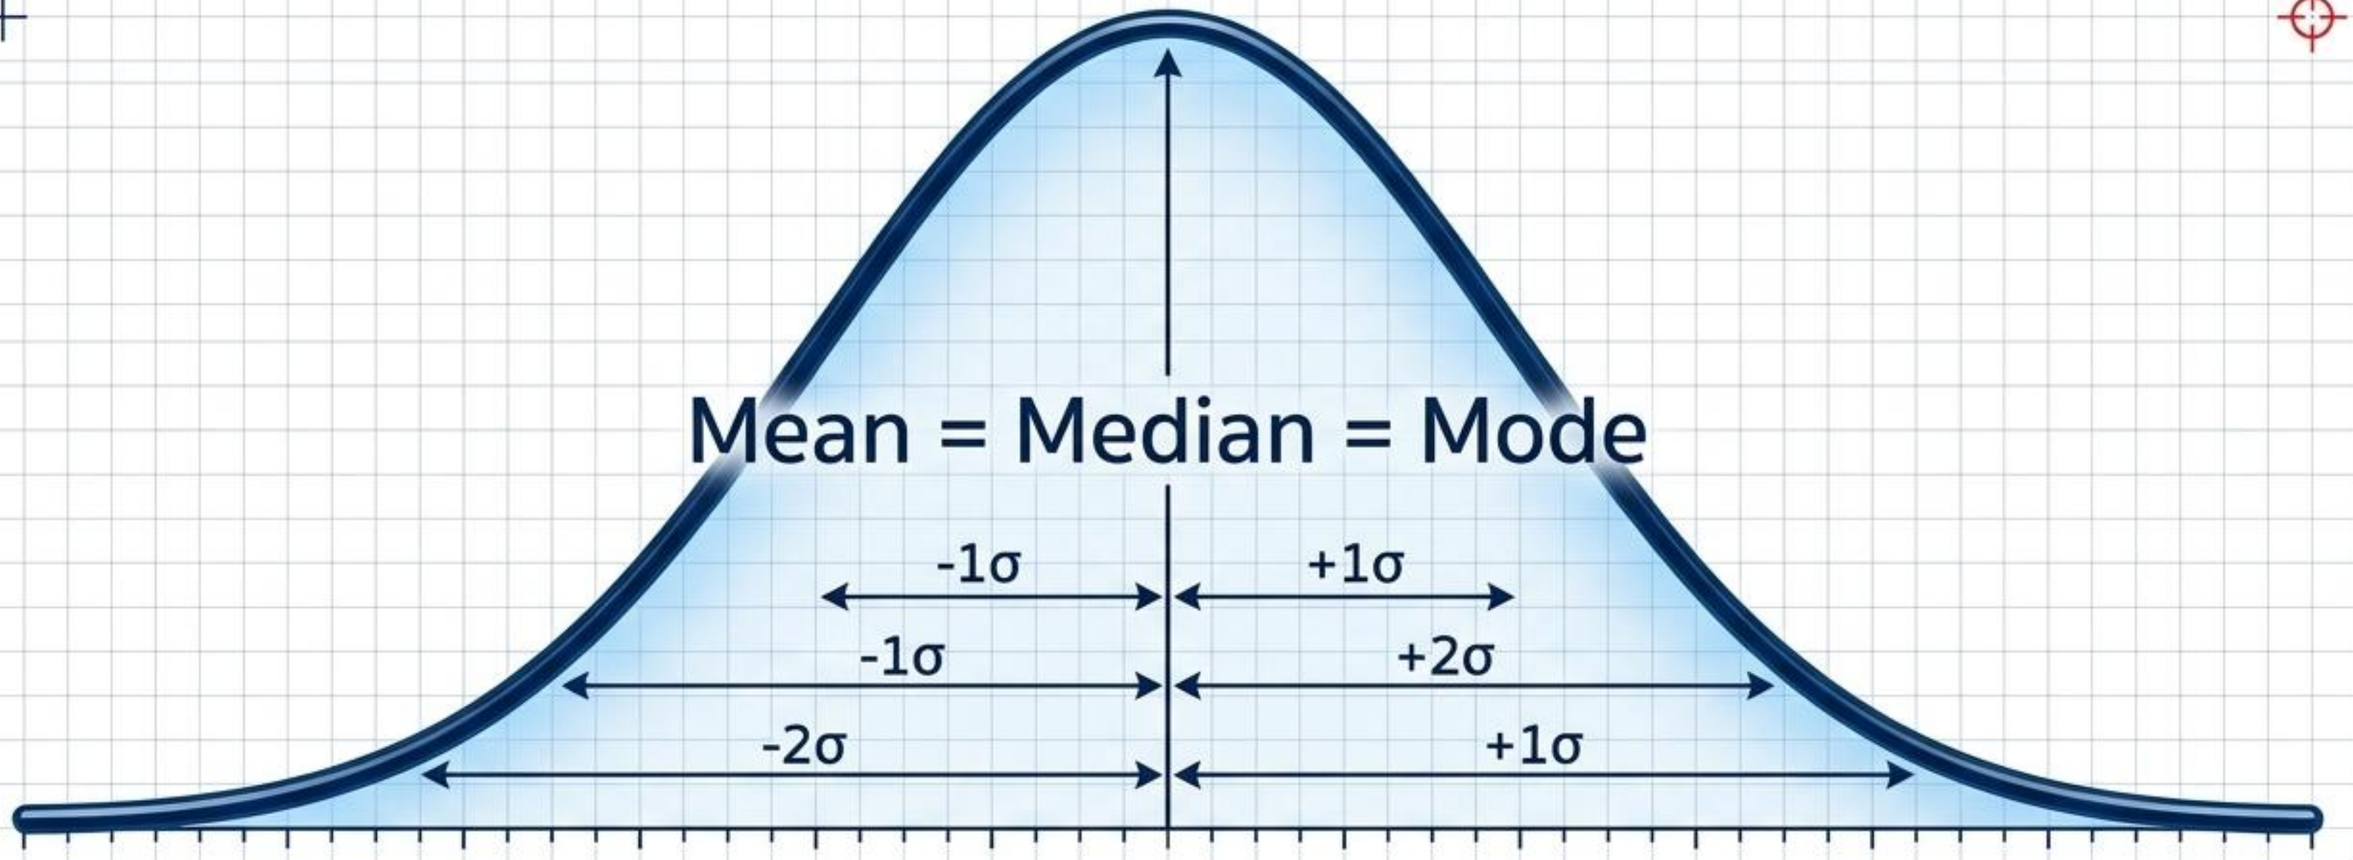


จากรูปนี้พบว่า $\mu_1 < \mu_2$

3. เส้นโค้งปกติที่มี $\mu_1 \neq \mu_2$ แต่ $\sigma_1 \neq \sigma_2$ โดยที่ $\sigma_1 > \sigma_2$ ตำแหน่งของจุดยอดอยู่ต่างกันและความโด่งของเส้นโค้งปกตทั้งสองรูปแตกต่างกันเส้นโค้งปกติจะมีลักษณะโด่งหรือแบนขึ้นอยู่กับค่าส่วนเบี่ยงเบนมาตรฐาน



จากรูปนี้พบว่า $\mu_1 < \mu_2$ และ $\sigma_1 > \sigma_2$



จากการแจกแจงความถี่ เมื่อข้อมูลไร้ซึ่งความผิดปกติและสมมาตรอย่างสมบูรณ์
โค้งปกติคือเป้าหมายสูงสุดของการสำรวจ

ปิดบท Error & Uncertainty

การกระจายตัวบอกอะไรเกี่ยวกับคุณภาพการสำรวจ?

1. ความสม่ำเสมอของผลวัด (Precision)

ถ้าวัดซ้ำภายใต้เงื่อนไขเดียวกันแล้วข้อมูลกระจายตัวน้อย แสดงว่าผลวัดมีความสม่ำเสมอสูงกว่า โดยทั่วไปส่วนเบี่ยงเบนมาตรฐาน (SD) ใช้ช่วยอธิบายการกระจายตัวนี้ได้

2. ความใกล้เคียงกับค่าอ้างอิง (Accuracy)

ต้องพิจารณาว่าผลวัดอยู่ใกล้ค่าที่เชื่อถือได้หรือไม่ ข้อมูลอาจกระจายตัวน้อยแต่คลาดจากค่าอ้างอิงมากได้

3. ความเหมาะสมต่อเกณฑ์งานสำรวจ

ต่อให้ผลวัดสม่ำเสมอ ก็ต้องตรวจสอบด้วยว่า**ความคลาดเคลื่อน**และ**ความไม่แน่นอน**อยู่ในเกณฑ์ที่งานนั้นยอมรับได้หรือไม่ เพราะงานสำรวจแต่ละประเภทมีข้อกำหนดต่างกัน

ก้าวต่อไป: จากการกระจาย สู่ความน่าจะเป็น

ข้อมูลที่กระจายตัว
บ่งบอกถึงสิ่งใดในงานสำรวจ?

การกระจายของข้อมูล
(Data Spread)

เราได้เรียนรู้วิธีวัดการแกว่งตัวของชุดข้อมูล

Error & Uncertainty

ความคลาดเคลื่อนและความไม่แน่นอนคือธรรมชาติของภาคสนาม

Probability
(ทฤษฎีความน่าจะเป็น)

เราจะใช้ทฤษฎีความน่าจะเป็น
เพื่อจัดการและทำนายความ
คลาดเคลื่อนเหล่านั้นในบทต่อไป

เพราะคุณภาพของงานสำรวจ ไม่ได้วัดกันที่การวัดได้เป๊ะในครั้งแรก
แต่วัดกันที่ความสามารถในการควบคุมและเข้าใจความคลาดเคลื่อน


Q
A
www.reallygreatsite.com